



生物信息学导论

陈同

中国中医科学院

中药研究所/中药资源中心

个人简介：陈同 男 有梦想的中药数据人



陈同
1988年出生
山东泰安



2005

哈尔滨

东北林业大学

国家生命科学与技术
人才培养基地 学士




2009

北京

中科院遗传发育所

生物信息学 博士
导师： 王秀杰



2015

北京

中国中医科学院中药所

中药大数据 副研究员
道地药材品质保障与
资源持续利用**全国重
点实验室** 青年 PI




学术任职

- *iMeta* (IF 44.4, 中科院一区)期刊
- 中国生物信息学会（筹）生物数据资源专委会
- 中国植物学会药用植物及植物药专委会
- 北京药理学会青委会
- 生信宝典公众号

执行主编
委员
青年委员
委员

生物信息学是将生物学问题转化为可计算问题，利用数据、算法和模型形成可验证生物学结论的学科



验证与迭代

实验或独立数据是否支持结论？若不支持，就修正问题、数据、算法或模型。

学习生物信息最好的时候是十年前，其次是现在



A decorative graphic on the left side of the slide. It features a series of concentric circles in shades of light green and olive green. In the center of the innermost circle is the number '01' in white. Surrounding the circles are four solid-colored dots: a dark olive green dot at the top right, a brown dot at the bottom left, and two smaller dots (one brown, one olive green) at the top right and bottom right respectively.

01


生物信息学的 发展和转变

从孟德尔到现代组学：生物学一直是一门数据科学

孟德尔手算的基因分离定律和自由组合定律


1. 现代遗传学创始人孟德尔在1856-1863年 28000 株豌豆杂交实验。
2. 豌豆的七种性状：种子形状（圆形、褶皱）、植株高度（高、矮）、种子颜色（黄色、绿色）、花颜色（白色、紫色）、果荚形态（饱满、皱缩）、果荚颜色（黄色、绿色）和花位置（高、低）。

- 表型差异显著
- 遗传效应强




Gregor Johann Mendel
1822-1884

“ My time will come. ”

Seed		Flower	Pod		Stem	
Form	Cotyledons	Color	Form	Color	Place	Size
 ROUND	 YELLOW	 WHITE	 FULL	 YELLOW	 AXIAL FLOWERS	 TALL
 WRINKLED	 GREEN	 PURPLE	 CONSTRICTED	 GREEN	 TERMINAL FLOWERS	 SHORT


历史上最好的实验？！

1. 孟德尔在研究豌豆之前，曾探索过10多种植物。
2. 最终选择了**豌豆**：自花授粉、花器官明显、易于杂交。
3. 开展了长达10年之久的遗传学实验。
4. 2年预实验，挑选了22个**纯合**豌豆品种。
5. 最后聚焦于7对性状。
6. 现代全基因组关联分析显示，豌豆性状的**遗传力冠绝**目前已研究过的物种，曼哈顿图信号强度前所未见。
这是教科书级的遗传定位事例。--- 程时锋老师



豌豆性状背后的控制基因或区域

1. 材料收集：697份来自全球六大洲、41个国家的豌豆核心种质。
2. 材料种质：豌豆种质在深圳、哈尔滨等多处实验基地进行种植，并同步进行表型记录。
3. 5年以来，研究团队共调查了豌豆种质的79个农艺性状，并进一步挖掘了大量与花期、株型、器官大小、结荚数目等性状相关的重要基因变异。



孟德尔定律的再发现 (35年)

1. **德弗里斯**受达尔文影响，认为生物体内的遗传物质以颗粒形式出现，称其为泛基因（pangene）。德弗里斯于1900年发表了《关于杂交种的性状分离定律》也发现自交的后代以近3:1的比例出现性状分离。
2. **科伦斯**曾跟随植物学家卡尔·奈格利学习，而奈格利曾与孟德尔**通信**，科伦斯在1896年阅读孟德尔的《植物杂交实验》后，将实验对象从玉米转向豌豆。1900年4月21日，科伦斯**看到了**德弗里斯发表的《关于杂交种的性状分离定律》，**次日**便寄出他的论文《有关杂交种子代表现的孟德尔定律》。
3. **切马克**在1888年就着手 豌豆杂交实验，与德弗里斯和科伦斯都曾**通信**。1900年6月，发表了论文《论人工杂交豌豆》。历史学家查阅切马克与其兄长，同时也是著名的生理学家阿尔敏·冯·切马克自1898年至1951年的**通信**，发现切马克对遗传定律有着深刻理解，最终恢复了切马克作为孟德尔定律“再发现者”的地位。


发表和信息传播很重要

孟德尔定律的发展 – 给未知事物命名


1. 英国遗传学家贝特森 (William Bateson, 1861年-1926年) 发明了“F₁代”、“F₂代”、“等位基因”、“合子”、“纯合子”、“杂合子”，他还从希腊字中创造了“遗传学genetics”来代替“传下去descent”。
2. 1909年，丹麦遗传学家约翰逊 (Wilhelm Ludwig Johannsen, 1857年-1927年) 引进了“基因 (gene)”这个概念来代替像“因子”、“性状”和“特征”之类的含糊术语，他还提出了表型 (phenotype, 也叫表现型) 和基因型 (genotype) 的概念，分别用来表示个体的外貌和实际的遗传类型。
3. 1910年，美国遗传学家摩尔根 (T.H.Morgan) 和他的学生们以果蝇为实验材料进行大量的杂交实验，发现了连锁与互换定律；1926年，发表了《基因论》，提出了基因在染色体上呈直线排列的理论，补充和发展了孟德尔的遗传学说，极大地推动了遗传学的发展，并于1933年获得了诺贝尔奖。

到现在为止大家还不知道基因是什么？直到 1952 年才确认 DNA 是遗传物质！

遗传物质的发现 – 2个著名的实验




1944年奥斯瓦尔德·艾弗里、麦克劳德、
麦克林肺炎双球菌转化实验




1952年赫尔希和蔡斯噬菌体侵染实验


遗传物质的发现 – DNA 双螺旋结构(1953)



It has not escaped our notice that the specific pairing we have postulated immediately suggests **a possible copying mechanism** for the genetic material. -- James Watson and Francis Crick



蛋白序列测序和中心法则提出





Frederick Sanger
(1918-2013)

**1951-1955年解析
牛胰岛素A、B 链
蛋白序列**

**1958,1980两次获
得诺贝尔化学奖**

A chain	B chain	
Gly	Phe	1
Ile	Val	
Val	Asn	
Glu	Gln	
Gln	His	5
Cys	Leu	
Cys	Cys	
Ala	Gly	
Ser	Ser	
Val	His	10
Cys	Leu	
Ser	Val	
Leu	Glu	
Tyr	Ala	
Gln	Leu	15
Leu	Tyr	
Glu	Leu	
Asn	Val	
Tyr	Cys	20
Cys	Gly	
Asn	Glu	
	Arg	
	Gly	
	Phe	25
	Phe	
	Tyr	
	Thr	
	Pro	
	Lys	
	Ala	30



1958-1962
Francis Crick
Marshall Warren Nirenberg

DNA → RNA → protein
中心法则
三联体密码子

世界“第一台”电脑ENIAC – 1946年2月15日

1. 占地150平方，重达30吨（约一间半教室大、六只大象重）。
2. 计算速度快，每秒5000次的加减运算。
3. 据传ENIAC每次开机，整个费城西区的电灯都会黯然失色。
4. 这部机器使用了18800个真空管，但真空管的损耗率相当高，几乎每15分钟就可能烧掉一支真空管，操作人员须花15分钟以上的时间才能找出坏掉的管子。




现在手机芯片计算次数在每秒**万亿**次

COMPROTEIN 第一个生物信息软件 (1958-1962)


- (A) IBM 7090大型机;
- (B) 载有单行FORTRAN代码的打孔卡;
- (C) 打孔卡形式存储的完整程序源代码;
- (D) COMPROTEIN输入输出简化流程图: 输入为埃德曼(Edman)肽序列, 输出为拼接好的蛋白质序列。

从蛋白降解数据中寻找重叠的多肽片段。对于小蛋白 (125个氨基酸大小的核酶) **几分钟**内就可以解析出结果。如果是人直接计算, 需要**几个月**才能完成。



<https://academic.oup.com/bib/article/20/6/1981/5066445>

生物信息学之母 – 手算不如机算



Margaret Belle (Oakley) Dayhoff (1925-1983)是一名美国物理化学家，也是生物信息学的先驱。

1. 1965 年出版《Atlas of Protein Sequence and Structure》，生物信息学的奠基之作。
2. 书中报告了当时已知的65种蛋白序列，按基因家族进行组织。
3. 促使了第一个公共数据库的成立，即1971年成立的蛋白质资源数据库 (Protein Information Resource, PIR)。
4. 率先将数学和计算分析方法应用于生物化学，创建了氨基酸的单字母编码，有效缩小蛋白质序列的文件体积。

<https://academic.oup.com/bib/article/20/6/1981/5066445>

Atlas 第一个分子生物学 “数据库” – 1960s


PIR A UniProt CONSORTIUM MEMBER
Protein Information Resource

About PIR Resources Search/Analysis Download Support

**INTEGRATED PROTEIN INFORMATICS RESOURCE FOR
GENOMIC, PROTEOMIC AND SYSTEMS BIOLOGY RESEARCH**

 The Universal Protein Resource (UniProt) provides the scientific community with a single, centralized, authoritative resource for protein sequences and functional information.
[UniProtKB](#) | [UniRef](#) | [UniParc](#) ■ Current release: 2023_05

PRO
Protein Ontology



- Representation of protein objects with descriptions and relationships
- [Browse PRO](#)
- Annotate with [RACE-PRO](#)

[Sample PRO report](#)

iPTMnet
Integrated Protein PTM Resource



- PTM enzyme-substrate-site relations
- Visual analysis of PTM networks, cross-talks, and conservation
- [Batch Retrieval](#)

[Sample iPTMnet report](#)

iProLINK
Literature Information & Knowledge



- Access to text mining tools and annotated corpora
- [RLIMS-P](#) extraction of kinase, substrate and site
- [miRtex](#) extraction of miRNA/target information

[Sample RLIMS-P report](#)

细胞色素c的三维结构模拟 – 1966年

Molecular Model-building by Computer


In which biochemists observe models of giant molecules as they are displayed on a screen by a computer and try to fold them into the shapes that they assume in nature

by Cyrus Levinthal

蛋白结构计算图形展示之父

莱文索尔悖论 (Levinthal's paradox) :
理论上, 即使对于较短的肽链, 采用暴力搜索寻找最低能量构象, 所需时间会**超过宇宙的年龄**。
实际上, 即使结构复杂的蛋白质也能非常**迅速**地完成折叠。


蛋白质并不是随机遍历全部构象, 而是在不均一的能量景观引导下, 通过一系列中间结构逐渐到达稳定状态。




CASP蛋白结构预测评估的突破和“终结”

STRUCTURE SOLVER

DeepMind's AlphaFold 2 algorithm significantly outperformed other teams at the CASP14 protein-folding contest — and its previous version's performance at the last CASP.





数据资源是生物智能计算的基石



美国华盛顿大学**戴维·贝克**因在“计算蛋白质设计”方面的贡献，荣获该奖项一半的奖金；另一半由谷歌“深度思维”公司创始人、英国科学家**戴密斯·哈萨比斯**和该公司美国科学家**约翰·乔普**共享，以表彰他们在“蛋白质结构预测”方面做出的成就。





测序数据的积累是巨大的




NCBI 中全基因组数据的序列数已达到40 亿条；国家生物信息中心汇交的数据已达 90PB，而且每隔 6-10 天就会增加 10PB。

测序过程鸟瞰图



测序接头什么时候会产生？

Sequencing



测序 Reads 单端读长超过模板长度时会产生测序接头。

测序



弹幕列表：


视频选集 (6/10)

自动连播 


P1	转录组概述-基本概念-PPT1-11页	19:12
P2	01-2-转录组概述-批次鉴定和校正-PPT12-20	22:34
P3	01-3-转录组概述-实验设计生物重复-PPT20-37	25:23
P4	05-1-富集分析理论-GO富集分析理论和可视化解...	26:00
P5	06-1-富集分析理论-GSEA理论和结果解读-	31:27
III P6	07-1-高通量测序原理-文库构建-1-22页PPT	22:31
P7	17-01-WGCNA理论-理论概述	36:53
P8	服务器安装Rstudio-server操作	11:06
P9	高通量数据中的批次效应鉴定和处理	39:05

DNA是生命的蓝图

基因组指一个物种所携带的一套完整的遗传物质。大部分物种的基因组为 DNA 序列，部分病毒的基因组是RNA序列。除了核基因组，真核生物还有线粒体基因组和叶绿体基因组。基因组包含了构造和维持一个机体生存和发育所需的全部信息。



测序物种的全基因组，建立遗传参考坐标系



基因结构与调控

结构注释 | 启动子与调控元件



基因功能与通路

功能验证 | 代谢与调控网络




遗传变异与群体

SNP / SV | 群体结构与溯源

参考基因组

统一坐标 · 基因目录 · 序列底图



进化与物种适应

亲缘关系 | 适应性 | 保护遗传学



育种与基因编辑

性状定位 | 抗病抗逆 | 精准改造




多组学与资源开发

转录 / 表观 / 蛋白 | 功能资源挖掘


人类基因组计划 HGP

Landmarks in genetics and genomics




人类基因组计划 HGP中的组装技术


A Hierarchical shotgun sequencing (NIH approach)




B Whole genome shotgun sequencing (Celera approach)



Shot-gun 鸟枪法测序



基因组的染色体挂载




Hi-C - 检测全基因组范围内染色质互作的明星技术


交联




酶切



标记



连接




纯化



测序



Hi-C - 检测全基因组范围内染色质互作的明星技术




▶ 动物：显著的棋盘格结构

共表达基因空间成簇

▶ 植物：较弱的棋盘格模式

共调控基因线性成簇

人类基因组计划 HGP测序是谁的基因组？




人类基因组计划草图中70%的基因组序列来源自一个混合血统的个体，剩下的30%来自另外19个个体，主要是欧洲，然后是亚洲、美洲、非洲等。




人类基因组什么时候测通的？

1. 2000 版获得了 90%基因组序列
 2. 2003 版获得了 92%基因组序列
 3. 2022 版填补了最后8%的空白
2. 携带的基因是我们成为人类的原因（例如决定脑容量大小相关基因），其包含的序列对染色体的分离以及细胞蛋白质的生产都有着极其重要的影响



这个基因组具有代表性吗？


1. 人类泛基因组整合 47 个个体基因组反应遗传多样性
2. 为当下的人类参考基因组(GRCh38)添加了 1.19亿碱基对(常染色体多态性序列，其中 9 千万来自于结构变异)和1115个重复基因。




<https://www.nature.com/articles/s41586-022-04601-8/>

36 个族群 58 个样本构建的中国人群泛基因组

1. 在现有人类参考基因组的基础上新增了约1.9亿个碱基对的新序列，包含约590万个小变异和约3.4万个结构变异（Structural variation, SV），涉及至少1367个蛋白编码基因复制事件等。
2. 其中，约500万个碱基对新序列存在于95%以上的单倍型中，被视为中国人群基因组核心序列，可能与中国人群特有的较为稳定的生物学功能或表型特征相关。




基于泛基因组的人类参考基因组



泛基因组作为更广泛的参考基因组


多个基因组

个体 · 品种 · 亚种 · 野生近缘种



泛基因组/图泛基因组

共有骨架 + 多条可选序列路径



物种完整序列空间

物种的“基因与变异总目录”

核心基因

可变基因

特异序列/SV/PAV

1

克服参考偏倚

发现参考基因组缺失序列

2

解析复杂变异

SV · PAV · CNV

3

研究基因簇演化


家族扩张与代谢通路

4

解释性状并育种


优异基因与单倍型

有了基因组为什么还要测序转录组?



- ▶ 表达活跃的基因
- ▶ 基因不同的可变剪接形式
- ▶ 融合基因
- ▶ 等位基因特异表达
- ▶ 基因的转录调控
- ▶ **时间动态性**
- ▶ **空间动态性**
- ▶ 诱导处理后表达变化
- ▶ 成本低

转录组的分析流程



普通转录组测序结果是混合样品的结果





Figure 1. Single cell gene expression profiling reveals cellular heterogeneity that is masked by bulk RNA-seq methods.

为什么要做单细胞转录组/基因组?

- ▶ 研究特殊时期基因表达状态，如从受精卵到胚胎发育早期
- ▶ 解析组织、器官的细胞类型组成，更好的了解器官构造和促进3D打印
- ▶ 肿瘤的异质性，不同肿瘤细胞可能有不同的突变位点或突变基因或表达状态，这也是单味药治疗肿瘤前期有效后期无效的原因之一



Nature重磅综述 | 关于RNA-seq, 你想知道的都在这



nature reviews genetics

Review Article | Published: 24 July 2019

RNA sequencing: the teenage years

Rory Stark, Marta Grzelak & James Hadfield


Nature Reviews Genetics **20**, 631–656(2019) | [Cite this article](#)

47k Accesses | **61** Citations | **373** Altmetric | [Metrics](#)


[中文全文翻译版](#)

[英文综述全文](#)

蛋白质组和代谢组 – 生命活动的执行者和体现者




微生物组研究方法



特点	局限
高通量，高成本	无法分离难培养的物种
研究物种多样性	- PCR有偏好性 - 只能研究分类信息和丰度
- 研究物种多样性和功能 - 发现新基因或基因组草图	- 无法得到基因表达信息 - 信息分析复杂
- 样本中含量低，捕获测序* - 同时研究DNA和RNA病毒	- 实验成本高 - 信息分析复杂
研究基因表达信息，寻找样本间表达差异	- 提取和纯化复杂， - 数据库信息不完善
- 获得蛋白表达谱 - 比较不同环境样本的蛋白差异	- 数据库信息不完善 - 总蛋白提取困难
- 获得代谢图谱 - 比较不同环境样本的代谢物差异	- 数据库信息不完善 - 难区分宿主和微生物的代谢物

整合多组学研究传统药用植物的作用机理

1. 中医药和人体都是复杂体系，需要整合分析。
2. 标准化、系统性的数据积累是关键。
3. 人工智能在解析数据过程中发挥着越来越重要的作用。



生物信息发展转变的 3 个阶段



**生物信息学不是因为有了计算机才出现，
而是因为生命科学的问题已经复杂到
无法仅靠人工观察和计算解决。**

A decorative graphic on the left side of the slide. It features a series of concentric circles in shades of light green and olive green. A solid olive green circle in the center contains the white number '02'. Three solid circles are also present: one olive green at the top right, one brown at the bottom left, and one olive green at the bottom right.

02

生物信息学研究 的特征

生物信息学是将生物学问题转化为可计算问题，利用数据、算法和模型形成可验证生物学结论的学科。

生物信息学问题的五个层次

1 描述

生物现象

有哪些物种?
差异基因有哪些?
有效成分有哪些?
细胞组成怎样?

2 关联

共同变化

环境-物种关联
基因-基因关联
基因-代谢物关联
突变-疾病关联

3 预测

评判未知

功能预测
年龄预测
疾病预测
代谢模型预测

4 因果

扰动检测

生态干扰
时序处理
虚拟细胞
生长发育


5 设计

新的序列、分子

生成新蛋白
生成新结构
生成新分子
设计新物种

生物信息学连接问题、数据、模型与实验

- ▶ 提出可检验的生物学问题
- ▶ 设计样本、对照、时间点与扰动
- ▶ 获取数据并完成质量控制
- ▶ 统计或AI建模，形成候选假设
- ▶ 用外部数据和实验验证
- ▶ 新结果进入下一轮研究



现代生物学数据种类繁多、结构复杂、噪声多样

序列数据



矩阵数据



结构数据



图像数据



网络数据



网络数据




表型数据

生物数据天然具有四类困难

- ▶ **高维小样本**: 特征数远大于样本数
- ▶ **噪声与批次**: 技术差异可能超过生物差异
- ▶ **样本不独立**: 同源序列、亲缘关系和重复患者
- ▶ **标签不可靠**: 数据库注释不等于实验事实

HIGH-DIMENSIONAL GEOMETRY CHALLENGES






03

生物信息学进入 人工智能时代

机器学习、深度学习、人工智能

生命科学与智能科学跨越 70 年的交汇


1953年
DNA双螺旋



John McCarthy



Marvin Minsky



Claude Shannon



Ray Solomonoff




Alan Newell



Herbert Simon



Arthur Samuel



Oliver Selfridge



Nathaniel Rochester



Trenchard More

1956年
人工智能



NOBELPRISET I KEMI 2024
THE NOBEL PRIZE IN CHEMISTRY 2024



KUNGL.
VETENSKAPS-
AKADEMIEN
THE ROYAL SWEDISH ACADEMY OF SCIENCES



David Baker
University of Washington
USA



Demis Hassabis
Google DeepMind
United Kingdom



John M. Jumper
Google DeepMind
United Kingdom

2024年
诺贝尔化学奖

生命科学与智能科学跨越 70 年的交汇


1953 | DNA双螺旋结构



1956 | 人工智能成为研究领域



2024 | 诺贝尔化学奖



两条科学路线，在70余年后汇合

DNA结构生物学 × 人工智能 → 蛋白质结构预测与设计

1953 | DNA双螺旋结构



生命信息获得明确的分子结构基础


1956 | 人工智能成为研究领域



人工智能成为独立的科学研究方向

汇合

2024 | 诺贝尔化学奖



计算蛋白质设计与蛋白质结构预测
获得诺贝尔化学奖认可

生物信息学正在从“解释生命”走向“预测和设计生命”

AI、机器学习和大模型的关系

1 人工智能 (Artificial Intelligence)

使机器表现出感知、推理、决策或行动能力的总领域

2 机器学习 (Machine Learning)

从数据中学习规律，是实现人工智能的主要方法之一

3 深度学习 (Deep Learning)

利用多层神经网络学习复杂表示

4 生成式 AI

生成文本、图像、音频、
蛋白质或分子结构等

5 基础模型

大规模预训练，具有较强的
通用性、迁移与涌现能力

提供推理与
生成能力

6 AI 智能体 (AI Agent)

面向目标，自主规划并执行任务的系统

基础模型 / 推理模型

目标理解 + 规划 + 记忆

工具调用 + 环境交互 + 行动

爱丁顿 1929 年提出无限猴子理论

理论

- 给定无限的时间（或无限多的猴子），让一只猴子在打字机上随机敲击，它几乎必然能够打出任何给定的文本，比如莎士比亚的全部著作。

实验验证

- 2023 年，英国一家动物园曾“实验”过，把一台电脑和键盘放进灵长类园区。
- 结果猴子们只打出了5页几乎全是字母“S”的纸，还把键盘给砸坏了。

模拟仿真

- 2011年，一位程序员让数百万个虚拟猴子模拟打字
- 真的成功生成了莎士比亚《维纳斯与阿多尼斯》的完整诗篇（但只是从随机生成的无数字符串中“匹配”了出来）



文字接龙 – 一次接一个词

Text sample:

LLMs learn to predict one word at a time

LLMs learn to predict one word at a time

LLMs learn to predict one word at a time

LLMs learn to predict one word at a time

LLMs learn to predict one word at a time

Input the LLM receives

LLMs learn to predict one word at a time

LLMs learn to predict one word at a time


LLMs learn to predict one word at a time

The LLM can't access words past the target

Target to predict

© 2024 Sebastian Raschka


基于概率的猜词游戏



为什么大语言模型可以猜测到合理的词呢？

大语言模型的预训练 – 文本转数字(embedding)

LLM pre-training at a high level




Token String	Token ID	Embedding / Vector Representation
'_The'	37	[-0.0513, -0.0584, 0.0230, ...]
'_teacher'	3145	[-0.0335, 0.0167, 0.0484, ...]
'_teaches'	11749	[-0.0151, -0.0516, 0.0309, ...]
'_the'	8	[-0.0498, -0.0428, 0.0275, ...]
'_student'	1236	[-0.0460, 0.0031, 0.0545, ...]
...	...	...

Vocabulary

词语接龙、完形填空和序列映射

Model architectures and pre-training objectives



什么是掩码语言建模 (MLM) ?

MLM是一种自监督学习目标，模型通过预测序列中缺失的词元进行学习。在训练期间：

- * 一些词元被随机替换为 [MASK]
- * 模型必须根据周围的上下文预测原始词元

例如，如果我们在句子中掩码单词 "fox"：

> "The quick brown [MASK] jumps over the lazy dog"

BERT将分析剩余的单词并尝试预测 "fox"。

Bidirectional Encoder Representations from Transformers

Next-token-prediction

The model is given a sequence of words with the goal of predicting the next word.

Example:
Hannah is a ____

Hannah is a *sister*
Hannah is a *friend*
Hannah is a *marketer*
Hannah is a *comedian*



Masked-language-modeling

The model is given a sequence of words with the goal of predicting a 'masked' word in the middle.

Example
Jacob [mask] reading

Jacob *fears* reading
Jacob *loves* reading
Jacob *enjoys* reading
Jacob *hates* reading

BERT的语法块 - embedding



BERT的语法块 – 自注意力

语境内的阅读理解

每个 token与所有其它 token进行比较

为每个 token 计算注意力分数

当前 token 的值更新为所有 token 的加权均值

先识别序列中最关键的token，再依据最相关的token调整每个序列各个 token的表示形式。简言之，它始终在追问：“哪些token值得关注？”，所以叫自注意力。



BERT的语法块 – 双向自注意力


语境内的阅读理解

每个 token 与所有其它 token 进行比较

为每个 token 计算注意力分数

当前 token 的值更新为所有 token 的
对它的加权均值

先识别序列中最关键的token，再依据最相关的token调整
每个序列各个 token 的表示形式。简言之，它始终在追问：
“哪些token值得关注？”，所以叫自注意力。



BERT的语法块 – 自监督训练

以自监督的方式进行预训练，优势在于可以直接使用原始、无标注的文本进行，超大规模文本语料。

无监督


无监督学习侧重于发现和利用数据中潜在的模式

自监督

自监督学习则是从数据本身挖掘已有的监督信号进行训练，无需人工干预



有监督

基于标注好的数据进行学习



BERT的语法块 – Transformer编码器

BERT的Transformer编码器实由多个重复堆叠的模块构成。每个模块都包含（双向多头）自注意力层和前馈网络，并在每层之后进行层标准化操作 (Norm) 和残差连接 (Add)。




BERT 的输入 – 分词、嵌入、位置

1. 输入的文本首先经过分词器处理获得如下图`Input`行的分词结果（注意`playing`被分成了`play`和`ing`，一个单词不一定是一个`token`），然后每个分词都对应一个索引值，可以通过查“词汇表”获得该分词的词向量（也可以随机生成一个词向量，当然每个`token`随机生成的词向量是一致的），也就是下图中的`token embeddings`行。
2. `Segment Embeddings`是两个句子的区分标识，例如`[CLS] my dog is cute [SEP] he likes playing [SEP]`那么对应的 Segment Embeddings 就是`00000011111`，`0`表示`SEP`前的句子，`1`表示`SEP`后的句子。
3. `Position Embeddings`是单词所在句子的位置编码。

Input	[CLS]	my	dog	is	cute	[SEP]	he	likes	play	##ing	[SEP]
Token Embeddings	$E_{[CLS]}$	E_{my}	E_{dog}	E_{is}	E_{cute}	$E_{[SEP]}$	E_{he}	E_{likes}	E_{play}	$E_{\#ing}$	$E_{[SEP]}$
	+	+	+	+	+	+	+	+	+	+	+
Segment Embeddings	E_A	E_A	E_A	E_A	E_A	E_A	E_B	E_B	E_B	E_B	E_B
	+	+	+	+	+	+	+	+	+	+	+
Position Embeddings	E_0	E_1	E_2	E_3	E_4	E_5	E_6	E_7	E_8	E_9	E_{10}

文本的词向量(embedding)反应了文本的固有属性




1. 词向量的数值参数，本质上对应着该词在数据中与其他所有词的“共现频率”统计信息，即该词在文本中与其他词在较近距离内共同出现的频率。
2. 若两个词倾向于与同一组词共现，则它们很可能语义相似；若一个词常与特定主题的词汇共现，则该词很可能与该主题相关。
3. 通过反映共现统计规律，词向量能够捕捉词语的某种意义。
4. 同义转述的词向量（例如“国王”是“男性”和“王室”的同义转述）会形成特定的几何关系，并可以进行加减运算。

传统专用模型和现代基础模型的区别


传统任务专用模型

每个任务分别准备数据、特征和模型







基础模型

一次大规模预训练，面向多个下游任务复用



传统任务专用模型	对比维度	基础模型
一个任务训练一个模型	建模方式	一个预训练模型适配多个任务
依赖人工设计或筛选特征	特征表示	自动学习可迁移的通用表示
以有监督学习为主	学习方式	以自监督预训练为主
相对较小的任务数据集	数据规模	大规模、多来源预训练数据
主要完成分类、回归等特定任务	能力范围	支持分类、预测、生成、推理与交互

如何表征氨基酸的属性



把生物数据的特征转换为表征表示

输入序列

M

A

D

E

F

G

H

同一条序列，可被转换为不同形式的数值表示

1 One-hot 编码

每个残基对应20维稀疏向量

	A	D	E	F	G	H	M	...
M							1	
A	1							
D		1						
E			1					
F				1				
G					1			
H						1		

固定 · 稀疏 · 只表达氨基酸身份

维度： $L \times 20$

2 属性编码

使用专家选择的理化性质

	疏水	电荷	大小	极性
M				
A				
D				
E				
F				
G				
H				

人工定义 · 可解释 · 任务相关

维度： $L \times k$

3 Embedding 表示

由蛋白质语言模型从数据中学习

Protein language model

M								
A								
D								
E								
F								
G								
H								

自动学习 · 稠密 · 上下文相关

残基表示： $L \times d$ Pooling → 序列向量 d


离散身份

人工生化知识

数据驱动的上下文语义


核心变化：由“指定氨基酸是什么”，发展为“模型学习它在当前序列中意味着什么”

蛋白质语言模型学习到了氨基酸的理化性质



氨基酸的生化特性在Transformer模型的输出嵌入中得到表征，此处通过t-SNE方法进行可视化。通过无监督学习，氨基酸残基被聚类为疏水、极性和芳香族三大类群，并展现出按分子量与电荷分布的总体组织结构。

蛋白质语言模型学习到了蛋白的属性信息




Transformer (trained)

Transformer (untrained)

Unigram

(a) Sequence representations (t-SNE)



Transformer (trained)

Transformer (untrained)

Unigram


(b) Sequence representations (PCA)

1. 蛋白质序列表征能够编码生物变异信息。
2. (a)图中每个点代表一个基因，并根据其所属的直系同源群进行着色（维度通过t-SNE进行降维）。
3. (b)基因按直系同源群着色，并以字符标签标明其物种。主成分分析在训练后的表示空间中识别出了一个物种轴（水平方向）和一个直系同源关系轴（垂直方向），但在未经训练或单字母表示空间中则未发现此类结构。

生物语言模型训练的基本概念


① 通用预训练

从大规模无标签生物数据中学习一般规律



② 下游适配

预训练模型可通过两条并列路线适配具体任务




先通过预训练学习通用生物规律，再通过零 / 少样本或微调适配具体任务

生物语言模型的训练

Input
Features

把蛋白质序列作为一句话，掩盖其部分氨基酸，喂入 BERT 模型进行训练

Output
Prediction




字词	→	碱基、氨基酸或基因
句子	→	序列或细胞状态
语义	→	结构、功能和调控关系

AI科研助手的价值来自迭代和验证




什么是智能体？ 智能体就是一个循环！




智能体的能力来自两个方面：大模型的理解能力和已有的工具能力


Agent – 智能体 – 不同程度的自主性




Agent – 智能体 – 不同形式的工具调用



1. LLM解析输入，识别要调用什么工具，并格式化好参数
2. 获得结果后再次返回给 LLM 梳理格式化输出。




Agent – 智能体 – 工具级联调用




1. 可以以固定顺序或让 LLM 自主决定顺序进行工具调用、结果处理。

AI智能体把模型、数据库、工具和执行环境连接起来


a Human bioinformatics workflow



b Workflow with agents



c Agent-based physical laboratory



一个研究型智能体通常需要：

- 理解问题并拆分任务
- 检索数据库与文献
- 标准化基因、物种和化合物名称
- 调用R、Python和专业软件
- 检查中间结果并修正计划
- 输出证据、代码、参数和待验证假设

人工智能时代的科研变了、分析变了 – 自主科学家

1



Claude Science

科研工作台

文献阅读 | `</>` 代码与数据分析 | 图表与论文草稿

2



Google AI Co-Scientist

多智能体假设生成系统

提出假设 | 多轮辩论 | 科研方案演化

3



The Virtual Lab

虚拟多专家实验室

AI 专家协作 | 研究设计 | 生物问题求解

4



The AI Scientist

自主科研闭环系统

想法生成 | 实验执行 | 论文写作

5



Agent Laboratory

开源科研工作流框架

文献调研 | 实验实现 | 报告生成

6



OpenScience

开源科研工作台

读论文 | `</>` 写代码 | 运行实验

人工智能时代的科研变了、分析变了 – 科研 skills

1 文献与知识



- 文献检索与搜索
- 文献阅读与总结
- 批量文献分析
- 引文网络分析
- 知识图谱构建
- 专利检索与分析

2 生物信息学



- 序列检索与比对
- 基因/蛋白分析
- 结构分析与预测
- 基因组学分析
- 转录组学分析
- 单细胞数据分析
- 生物网络分析

3 化学信息学



- 化合物检索
- 分子性质计算
- 分子相似性搜索
- 分子对接
- QSAR 建模
- ADMET 预测
- 化学反应预测

4 药物发现



- 靶点发现与验证
- 虚拟筛选
- 先导化合物优化
- 药物重定位
- 药效预测
- 毒性预测
- 药物相互作用预测

5 实验与数据分析



- 实验方案设计
- 实验数据分析
- 统计分析
- 图表生成与可视化
- 数据清洗与处理
- 高通量数据分析
- 质谱数据分析

6 医学与临床



- 疾病知识检索
- 临床指南查询
- 病例分析与总结
- 生物标志物发现
- 临床试验分析
- 真实世界数据分析
- 医学影像分析

7 数据库与资源调用



- NCBI 相关资源调用
- UniProt / PDB / KEGG 调用
- ChEMBL / PubChem 调用
- DrugBank / HMDB 调用
- ClinicalTrials.gov 调用
- GTEx / TCGA 调用
- OMIM / DisGeNET 调用

8 通用科研技能



- 代码生成与调试
- 脚本编写 (Python/R)
- 数据转换与格式处理
- API 调用
- 文件处理
- 报告/论文写作
- 幻灯片生成

KDense
Scientific
Agent
Skills

A decorative graphic on the left side of the slide. It features a series of concentric circles in shades of light green and olive green. In the center of the innermost circle is the number '04' in white. Surrounding the circles are four solid-colored dots: a dark olive green dot at the top right, a brown dot at the bottom left, and two smaller dots (one brown at the top right and one olive green at the bottom right) further out on the right side.

04


生物大模型与 科学发现

让世界充满 AI

AlphaFold2 生物计算诺贝尔奖




T1037 / 6vr4
90.7 GDT
(RNA polymerase domain)





T1049 / 6y4f
93.3 GDT
(adhesin tip)

● Experimental result
● Computational prediction




AlphaFold3 从蛋白结构扩展到生物分子互作



- ▶ 蛋白质与蛋白质
- ▶ 蛋白质与DNA或RNA
- ▶ 蛋白质与小分子配体
- ▶ 抗体与抗原
- ▶ 离子和修饰残基

序列基础模型正在超越传统相似性搜索



传统方法关注:

- ▶ 序列相似性、保守结构域和进化关系

基础模型进一步学习:

- ▶ DNA调控语法与变异效应
- ▶ 蛋白质结构、功能和远缘同源关系
- ▶ 可迁移的序列嵌入
- ▶ 新的蛋白质或调控序列

!! 模型越大并不保证每个任务都更好。

序列基础模型正在超越传统相似性搜索

Evo

2024 · Science

原核基因组模型



细菌



古菌



噬菌体

0.3 T

核苷酸

131 kb

最大上下文

7 B

参数量

擅长	微生物基因与基因组建模
生成	CRISPR / 噬菌体 / 原核序列生成
架构	StripedHyena

Evo 2

2025 发布 · 2026 Nature

全生命域基因组模型



细菌



古菌



噬菌体



植物



动物/人

9.3 T

核苷酸

1 Mb

最大上下文


7B / 40B

参数量

新增	真核基因结构与长距离调控
应用	变异效应、调控序列与基因组生成
架构	StripedHyena 2

T: Trillion万亿


序列基础模型参数量从千万到百亿





单细胞基础模型尝试学习可迁移的细胞状态

预训练：大规模单细胞表达图谱

- ▶ 细胞类型注释
- ▶ 批次整合与细胞嵌入
- ▶ 基因调控网络推断
- ▶ 多组学整合
- ▶ 基因或药物扰动响应预测



单细胞基础模型尝试学习可迁移的细胞状态



<https://www.nature.com/articles/s12276-025-01547-5/figures/3>


<https://github.com/OmicsML/awesome-foundation-model-single-cell-papers>

多模态模型正在走向可预测的虚拟细胞

虚拟细胞希望联合：

- ▶ 基因组和调控序列
- ▶ 转录、蛋白和代谢状态
- ▶ 单细胞与空间组学
- ▶ 显微图像与细胞形态
- ▶ 基因敲除、药物和环境扰动


目标是预测状态变化，而不是只复述已有知识。



AI用于中药天然产物研究和酶的筛选

- 药用植物基因组与转录组 → 生物合成基因簇与候选酶挖掘
- 酶—底物和反应关系预测 → 通路设计与工程菌优化
- 自动化筛选和实验验证 → 新数据反馈模型

最终目标是提高候选命中率，设计出更高效的酶和通路。





A decorative graphic on the left side of the slide. It features a series of concentric circles in shades of light green and olive green. In the center of the innermost circle is the number '05' in white. Surrounding the circles are four solid-colored dots: a dark green dot at the top right, a brown dot at the bottom left, and two smaller dots (one brown at the top right and one dark green at the bottom right) further out on the right side.

05

可信 AI 与科研 规范

AI可用到可信

图灵测试 (1950年)



一名人类评判员与两个隐藏的参与者进行对话——一个人类和一个机器。评判员通过打字的方式与两个参与者交流，但无法直接看到他们。对话的方式可以是文字游戏、回答问题或者任何形式的交流。如果评判员无法一致地区分出哪个是人类参与者，哪个是机器参与者，那么机器就可以说通过了图灵测试，表明它能够展现出与人类相似的智能水平。

猜一猜这些是什么？ - 文生图（2022 年）



猜一猜这些是什么？ - 文生图（2022 年）



娃娃菜



鸡腿菇





鸡蛋灌饼



驴肉火烧

明显 AI 生图的痕迹



AI会生成看起来合理但事实错误的答案


常见表现：

- ▶ 虚构论文、DOI、软件包或函数
- ▶ 参数名称和版本不匹配
- ▶ 用常识补齐数据中不存在的信息
- ▶ 把相关性写成因果关系
- ▶ 给出流畅但无法复现的解释

引用必须真实，并能支持结论。

FINDING THE FABRICATIONS

A *Nature* analysis started with more than 4,000 randomly selected publications from 2025 and then used an artificial-intelligence tool to flag problematic citations. *Nature*'s news team manually checked the 100 publications judged to be most suspicious. For 65 of those, at least one citation did not seem to point to a real publication and so might have been hallucinated.



©nature

因AI生成图片和编造文献被撤稿

作者使用AI工具生成参考文献（瞎编文献）及图片，违反了PNAS 政策规定。

作者确认，他们使用了Microsoft Copilot将引用文章的PubMed ID转换为格式化的参考文献列表，但提交前并未对这些参考文献进行核实。



Retracted article

See the [retraction notice](#)

[Comment](#)

> [Proc Natl Acad Sci U S A. 2025 Oct 7;122\(40\):e2520203122.](#)

doi: 10.1073/pnas.2520203122. Epub 2025 Sep 29.

Curiouser and curiouser: Meningeal lymphoid structures in the aging brain

[Iftach Shaked](#) ^{1 2}, [Dan Frenkel](#) ^{3 4}

Affiliations + expand

PMID: 41021818 PMCID: [PMC12519197](#) DOI: [10.1073/pnas.2520203122](#) [↗](#)

Retraction in

[Retraction for Shaked and Frenkel, Curiouser and curiouser: Meningeal lymphoid structures in the aging brain.](#)

[No authors listed]

[Proc Natl Acad Sci U S A. 2026 Jul 14;123\(28\):e2621866123.](#) doi: 10.1073/pnas.2621866123. Epub 2026 Jul 6.

PMID: 42406977 No abstract available.


数据泄漏会让模型性能虚高

生物数据中的典型泄漏：

- ▶ 同一患者的多个样本进入训练集和测试集
 - ▶ 高度同源序列被随机拆开
 - ▶ 同一药物骨架或实验批次同时出现
- 同时出现
- ▶ 先用全体数据筛特征，再划分测试集
 - ▶ 测试集进入基础模型预训练数据



数据泄漏会让模型性能虚高




类别不平衡时，高准确率可能毫无意义

假设10个阳性、90个阴性：

全部预测为阴性，Accuracy仍为90%。

- Precision：预测阳性中有多少是真的
- Recall：真实阳性中找回了多少
- F1：Precision与Recall的调和平均
- PR-AUC、MCC和模型校准
- 与简单基线模型比较



模型可能学到批次，而不是生物学


危险设计：

疾病组全部在医院A测序；
对照组全部在医院B测序。

模型准确率很高，但可能识别的是：

- ▶ 医院、仪器或建库批次
- ▶ 测序深度和数据质量
- ▶ 样本处理时间

批次与分组完全混杂时，统计校正也无法补救。



数据偏见-DARPA的“坦克识别”传说

目标

训练一个模式识别算法从照片中自动识别林中是否有敌方坦克。

数据

研究人员拍摄了一组有坦克在树林中的照片，和一组没有坦克的树林照片

训练


算法训练后，在“独立”测试集上表现**极其出色**，几乎能100%准确地区分“有坦克”和“无坦克”的照片。

应用

真实世界测试时，算法完全失败了

干扰

“有坦克”的照片阴天拍色；而“无坦克”的照片则晴天的拍摄。实际上训练了一个相当精确的“阴天 vs. 晴天”分类器




识别的是坦克还是图形背景？

可重复分析必须保留完整证据链

至少记录:


- ▶ 原始数据、元数据和样本关系
- ▶ 代码、参数和随机种子
- ▶ 软件、模型和数据库版本
- ▶ Conda、renv或容器环境
- ▶ 训练集、验证集和测试集划分
- ▶ AI提示、生成代码和人工修改

最终目标是让结果能被重现。



模型/智能体配合确定性生信分析流程效果更稳定

- ▶ 当我们允许智能体使用 gget virus 后，所有智能体的准确率都提升至 90% 以上，其中 GPT-5.5 的准确率最高，达到 99.7%。
- ▶ 不同运行批次之间的结果波动基本消除，不同模型之间的性能差距也显著缩小。



AI时代同样需要学好Linux、R、Python和统计学

 Linux 与命令行	难以判断 AI 实际执行了什么	!
 数据结构	难以及时发现输入格式和字段错误	!
 统计学	难以评价显著性和模型性能	!
 实验设计	难以识别批次效应与混杂因素	!
 生物学知识	难以判断结果解释是否合理	!

操作门槛 ↓
AI 可以完成更多步骤



审查要求 ↑
必须验证输入、方法与解释

**AI 可以替代部分操作，
但不能替代专业判断**

还是需要自己学好代码 – 系列教程

Bioinformatics resource

生信Linux教程



Author: system
Last update: 2020-12-18
Version: 1.0

生信R教程



Author: system
Last update: 2020-12-18
Version: 1.0

易生信转录组视频教程



Author: system
Last update: 2020-12-18
Version: 1.0

Adobe Illustrator-图形编辑和排版系列教程



Author: system
Last update: 2020-12-18
Version: 1.0

生信Linux视频教程



Author: system
Last update: 2020-12-18
Version: 1.0

生信Python视频教程



Author: system
Last update: 2020-12-18
Version: 1.0

Cytoscape网络图视频教程



Author: system
Last update: 2020-12-18
Version: 1.0

易生信R绘图视频教程




Author: system
Last update: 2020-12-18
Version: 1.0

科研AI还涉及隐私、知识产权

- ▶ 不向公共模型上传未公开的人类基因组或临床数据
- ▶ 遵守知情同意、受控访问和合作协议
- ▶ 核查训练数据、生成代码和图片的授权
- ▶ 按期刊和单位要求披露AI使用
- ▶ 对病原体、毒素和敏感设计设置额外审查


技术可行不等于伦理和合规上可行。



研究生需要形成五种可迁移能力

1. 问题定义：把科学问题转成可检验假设
2. 数据能力：整理、质控并理解数据来源
3. 计算能力：用代码、统计和模型完成分析
4. AI协作：让模型调用知识、代码和工具
5. 批判验证：识别错误并形成实验闭环

会使用工具只是起点，能够验证结论才是目标。





06

AI 智能体操作 演示过程记录

智能体

OpenAI 的 NGS 分析 – 安装 NGS 插件

插件

在你常用的工具中使用 Codex

Q NGS



Life Sciences NGS Analysis
Guided NGS routing and loc...

 正在安装



NGS Analysis Workbench
Analyze sequencing data

安装

OpenAI 的 NGS 分析 – NGS 插件有哪些技能

Life Sciences NGS Analysis



Life Sciences NGS Analysis

Guided NGS routing and local execution for sequencing analysis

A guided intake, routing, and execution plugin for next-generation sequencing workflows. It helps Codex inspect local sequencing inputs, ask only the missing assay-specific questions, choose public or freely accessible runtime-installable packages where possible, check existing tool availability before any install, and execute supported local workflows with validation, logs, manifests, QC reports, and artifact indexes. It includes deeper decision skills for BCL demultiplexing, FASTQ QC execution and interpretation, germline, somatic and UMI-panel DNA variants, bulk RNA-seq count generation and differential expression, ATAC-seq, ChIP-seq/CUT&RUN/CUT&Tag, and embedded post-count scRNA-seq QC.

技能 18

... [立即试用](#)



Amplicon Microbiome

Plan 16S/ITS/amplicon microbiome analysis



NGS Router

Route sequencing inputs to the right public analysis workflow



ATAC-seq Peaks QC

Deep ATAC-seq QC, peak, and accessibility planning



BCL to FASTQ

Validate BCL run folders and plan FASTQ conversion



Bulk RNA-seq Counts

Deep FASTQ-to-count processing and QC for bulk RNA-seq



Bulk RNA-seq DE

Deep differential-expression design and result planning



ChIP/CUT&RUN Peaks QC

Deep ChIP-seq, CUT&RUN, and CUT&Tag peak workflow planning



Germline DNA Variants

Deep germline WGS/WES/panel variant workflow planning



Somatic DNA Variants

Deep tumor-normal or tumor-only somatic variant workflow planning



UMI Panel Variants

Deep targeted panel and UMI-aware variant workflow planning



DNA Variants

Plan WGS/WES/panel variant calling



Epigenomics Peaks

Plan ATAC/ChIP/CUT&RUN/CUT&Tag analysis



FASTQ QC

Run public FASTQ QC and trimming workflows



NGS Runtime

Check sequencing packages before installing



Single-cell RNA-seq

Plan scRNA-seq counting, QC, and annotation



Shotgun Metagenomics

Plan shotgun metagenomics profiling



OpenAI 的 NGS 分析 – 转录组的技能都有什么



Bulk RNA-seq Skill

Plan bulk RNA-seq counts and DE analysis

Use this skill as the bulk RNA-seq dispatcher. Route FASTQ/BAM processing to count-generation QC, and route count-matrix statistical analysis to differential-expression guidance.

Essential Inputs

Confirm:

- organism and genome build
- FASTA and GTF, or supported nf-core genome key
- paired-end or single-end reads
- strandedness, or whether to infer strandedness
- sample sheet and metadata
- counts-only vs differential expression
- contrasts, covariates, and batch terms for differential expression

Dispatch

- FASTQ or aligned reads to raw counts, transcript estimates, or MultiQC summaries: `ngs-bulk-rnaseq-counts-qc`
- Raw count matrix plus sample metadata to contrasts, plots, and DE result tables: `ngs-bulk-rnaseq-differential-expression`

If the user asks for both, run count-generation planning first and start differential

Public Default

Prefer `nf-core/rnaseq` for standardized processing when a stable container or HPC runtime is available. Use the `local_light` Snakemake/Salmon path when Docker, registry egress, or Nextflow process containers are unavailable and a compact local run is appropriate.

Plugin-Owned Local Paths

Use the counts/QC runner for local FASTQ-to-matrix execution:

Bash

```
python plugins/ngs-analysis/scripts/run_bulk_rnaseq_counts_qc.py \
--sample-sheet samplesheet.csv \
--fastq-root path/to/fastqs \
--transcriptome-fasta reference/transcriptome.fasta \
--genome-fasta reference/genome.fa \
--annotation-gtf reference/genes.gtf \
--execute
```

OpenAI 的 NGS 分析 – 转录组的技能都有什么

Use the differential-expression runner when the user already has a count or expression matrix:

Bash

```
python plugins/ngs-analysis/scripts/run_bulk_rnaseq_de.py \  
  --count-matrix count_matrix.tsv \  
  --sample-metadata sample_metadata.tsv \  
  --contrasts contrasts.tsv \  
  --execute
```

If strandedness is unknown, run inference or use the pipeline's strandedness detection before committing to final counts.

Local execution run:

Bash

```
python plugins/ngs-analysis/scripts/run_bulk_rnaseq_counts_q \  
  --sample-sheet samplesheet.csv \  
  --fastq-root path/to/fastqs \  
  --transcriptome-fasta reference/transcriptome.fasta
```

The local runners create a standard run envelope with `run_manifest.json`, `config.json`, `validation/`, `logs/`, `versions/`, `artifact_index.json`, and `summary.md`. Do not depend on development-only eval harness paths in a shared package.

Downstream

Only start DESeq2/edgeR/limma analysis after confirming biological replicates, design formula, and contrasts. Preserve the raw count matrix and sample metadata.

OpenAI 的 NGS 分析 – 简单粗暴开始分析

🔗 Life Sciences NGS Analysis 执行转录组数据分析

耗时 2分钟 57秒 >

目前无法执行：工作区 `/Users/ct/work/Obsidian/NGS` 为空，没有 FASTQ、count matrix、样本表或参考文件；本机也缺少 Nextflow、Snakemake 和 Docker。

请将以下任一套数据放入该目录：

- FASTQ: `*.fastq.gz` + 样本表 (`sample_id, fastq_1, fastq_2, condition, replicate, batch`)
- 已有表达矩阵: count matrix + sample metadata + contrasts
- 同时说明: bulk RNA-seq 还是单细胞 RNA-seq、物种/参考基因组、目标是 QC/定量/差异表达，以及是否允许安装依赖

收到后我会先验证样本与原始数据的一一对应关系，再进行运行时预检和分析；不会修改 raw 数据或自动安装软件。

OpenAI 的 NGS 分析 – 简单粗暴开始分析 (思考过程1)

我会使用 Life Sciences NGS Analysis 的工作台流程，先检查当前 NGS 工作区的数据与项目状态，再判断是从 FASTQ 开始还是已有 count matrix；确认输入、分组和分析目标后再执行可复现的转录组流程。

🔍 已在 MEMORY.md 中搜索“NGS|transcript|RNA-seq|FASTQ|count matrix|转录组|bulk”

工作区记忆显示，这类任务应先做严格的 metadata→FASTQ 解析与输入门禁，并保持 raw 数据不变；我会按这一边界检查，避免在样本对应关系不明确时启动流程。

📁 加载了工具读取文件

已确定这是一个“宽泛入口”，当前先走数据理解阶段；这一步只读取并建立起始点评估，不会安装软件、改动输入或生成执行计划。接下来我检查工作区中的 FASTQ、count matrix、样本信息和参考文件。

🔗 已使用 Ngs Compute和Ngs Analysis Workbench 集成读取文件

检查结果：当前 `/Users/ct/work/Obsidian/NGS` 没有可见的测序文件、样本表、count matrix 或参考基因组文件；本机也没有可直接运行的 Nextflow/Snakemake、Docker 或容器环境。已有可选工作流包括 nf-core/rnaseq 3.26.0 和本地 bundled bulk RNA-seq，但现在还不能安全选择或启动。

OpenAI 的 NGS 分析 – 简单粗暴开始分析（思考过程2）

☞ 已读取文件

目前无法执行：工作区 `/Users/ct/work/Obsidian/NGS` 为空，没有 FASTQ、count matrix、样本表或参考文件；本机也缺少 Nextflow、Snakemake 和 Docker。

请将以下任一套数据放入该目录：

- FASTQ: `*.fastq.gz` + 样本表 (`sample_id, fastq_1, fastq_2, condition, replicate, batch`)
- 已有表达矩阵: count matrix + sample metadata + contrasts
- 同时说明: bulk RNA-seq 还是单细胞 RNA-seq、物种/参考基因组、目标是 QC/定量/差异表达，以及是否允许安装依赖

收到后我会先验证样本与原始数据的一一对应关系，再进行运行时预检和分析；不会修改 raw 数据或自动安装软件。

OpenAI 的 NGS 分析 – 放置好数据，按要求回复

数据已放置好，bulk RNA_seq, 参考基因组在 genome 目录下，目标是差异表达

耗时 7分钟 33秒 >

数据检查已完成，尚未启动分析：

- 8 个双端 FASTQ, 4 个 `trt`、4 个 `untrt`
- 所有 FASTQ 压缩完整，R1/R2 reads 数量一致且首条 read 可配对
- 可执行比较： `trt - untrt`
- `DESeq2`、`edgeR`、`limma` 已安装
- 缺少定量工具：Salmon/STAR、FastQC、MultiQC、Snakemake
- 当前参考仅包含 `chr20`、1,391 个基因，不能代表全转录组

请确认两点后我即可继续：

1. 使用完整基因组参考，还是接受当前 `chr20` 子集分析？
2. 是否允许我创建隔离 conda 环境并安装所需工具？

推荐回复： `使用完整参考，允许安装` 。若确实只想分析 `chr20`，请回复： `接受 chr20，允许安装` 。

OpenAI 的 NGS 分析 – 数据检查 (思考过程)

耗时 7分钟 33秒 ∨

我会继续按 bulk RNA-seq → 差异表达路径处理：先核对 FASTQ、样本表、`genome/` 下的 FASTA/GTF/index，以及是否已有 count matrix；然后验证样本对应关系、重复和分组，再决定从定量开始还是直接进入差异表达。raw 数据保持不变。

📄 运行了命令

输入已找到：8 个双端样本（4 个 `untrt`、4 个 `trt`），样本表能支持 `trt - untrt` 的差异比较。检查同时发现 `genome/Genome.fa.fai` 只有 `chr20`，GTF 也需要核对是否仅含 chr20；这会决定结果能否称为“全转录组”分析。现在进行输入完整性、配对关系和参考覆盖范围检查。

📄 运行了命令

输入门禁结果良好：8 个 FASTQ 均可解压，样本表与文件名一一对应，且每个样本都有 R1/R2；设计为两组各 4 个生物学样本，可支持 `trt - untrt`。但当前缺少定量工具，差异表达不能直接从 FASTQ 开始；我继续确认本地 runner 是否能直接使用现有 FASTA/GTF，以及 chr20 参考的限制。

📄 已读取文件运行了命令

定量路径确认完毕：当前只有 FASTQ，没有可直接用于 DESeq2/edgeR 的 count matrix；必须先做比对/定量。现有参考确实是仅 `chr20` 的 1,391-gene 注释子集，因此即使运行成功，结果也只能解释为 chr20 子集，不能称为全基因组/全转录组差异表达。我正在核对 R 统计包是否可用。

OpenAI 的 NGS 分析 – 执行操作

接受 chr20, 允许安装

你在 9分钟 41秒 后停止了

已确认执行条件：按当前 chr20 参考进行分析，并允许安装依赖。我会在工作区创建隔离 conda 环境，安装 Salmon/Snakemake/FastQC/MultiQC 及生成转录本 FASTA 所需工具；随后生成派生样本表与 contrasts 文件，先做定量 QC，再用 DESeq2/tximport 进行 `trt - untrt` 差异表达。raw FASTQ 和原始参考不改动。

☒ 已运行 `/Users/ct/miniforge3/bin/conda create --yes --solver libmamba --prefix /Users/ct/work/Obsidian/N...`

隔离环境创建被本机沙箱拦截：conda 需要写入 `/Users/ct/miniforge3/pkgs` 和用户缓存目录，而这些目录不在当前工作区写权限内。将按已获准的安装范围重试一次授权的 conda 下载；不会修改 raw 数据。

☒ 已运行 `/Users/ct/miniforge3/bin/conda create --yes --solver libmamba --prefix /Users/ct/work/Obsidian/N...`

安装已开始，当前 conda 正在下载约 482 MB 的 osx-arm64 环境包；这是首次创建隔离环境，主要耗时在 OpenJDK/Snakemake/MultiQC 依赖。完成后我会立即做工具版本预检，不会把这些包安装到系统 Python。

继续之前的操作

OpenAI 的 NGS 分析 – 执行操作

接受 chr20, 允许安装

你在 9分钟 41秒 后停止了

已确认执行条件：按当前 chr20 参考进行分析，并允许安装依赖。我会在工作区创建隔离 conda 环境，安装 Salmon/Snakemake/FastQC/MultiQC 及生成转录本 FASTA 所需工具；随后生成派生样本表与 contrasts 文件，先做定量 QC，再用 DESeq2/tximport 进行 `trt - untrt` 差异表达。raw FASTQ 和原始参考不改动。

☒ 已运行 `/Users/ct/miniforge3/bin/conda create --yes --solver libmamba --prefix /Users/ct/work/Obsidian/N...`

隔离环境创建被本机沙箱拦截：conda 需要写入 `/Users/ct/miniforge3/pkg`s 和用户缓存目录，而这些目录不在当前工作区写权限内。将按已获准的安装范围重试一次授权的 conda 下载；不会修改 raw 数据。

☒ 已运行 `/Users/ct/miniforge3/bin/conda create --yes --solver libmamba --prefix /Users/ct/work/Obsidian/N...`

安装已开始，当前 conda 正在下载约 482 MB 的 osx-arm64 环境包；这是首次创建隔离环境，主要耗时在 OpenJDK/Snakemake/MultiQC 依赖。完成后我会立即做工具版本预检，不会把这些包安装到系统 Python。

继续之前的操作

OpenAI 的 NGS 分析 – 执行完成

耗时 17分钟 12秒 >

已完成 bulk RNA-seq 差异表达分析。

- 样本: untrt 4 个、trt 4 个
- 比较: trt vs untrt
- 方法: Salmon → tximport → DESeq2
- 参考范围: 仅 chr20
- Salmon mapping rate: 94.0–95.1%, 文库方向均为 IU
- 检验基因: 424 个
- 显著差异基因: 11 个 ($FDR < 0.05$, $|\log_2FC| \geq 1$)
- 代表性基因: SAMHD1、TLDC2、ZHX3、FLRT3、NCOA3、ACSS1 等

主要文件:

-  差异表达完整结果
-  显著差异基因
-  PCA 图
-  MA 图
-  FastQC MultiQC 报告
-  Salmon MultiQC 报告
-  分析总结




注意: 所有结果仅代表 chr20 子集, 不能直接解释为全基因组差异表达。

- ▶ 总耗时 35 分钟 (分析+部署环境+运行)
- ▶ 无需操作人员指导排错
- ▶ 数据核查、程序运行、结果输出
- ▶ 缺少结果总体报告
- ▶ 缺少总的分析参数


OpenAI 的 NGS 分析 – 结果查看

PCA: chr20 gene expression
DESeq2 VST



PCA 图

DESeq2 MA: trt vs untrt (chr20)



MA 图

OpenAI 的 NGS 分析 – 结果查看 DE_report.md

Bulk RNA-seq differential expression report

本次分析使用 8 个双端样本 (untrt 4 个、trt 4 个)，比较为 `trt - untrt`。参考序列和注释仅包含 `chr20`，因此所有表达量和差异表达结论均限定在 chr20 子集，不能外推到全基因组。

质控与定量

- 16 个 FASTQ 均通过 gzip/配对读取校验。
- Salmon 文库方向自动判定在 8 个样本中一致为 `IU`。
- Salmon mapping rate 为 94.0–95.1%。
- FastQC 与两份 MultiQC 报告已生成。



差异表达

方法为 Salmon → tximport (`countsFromAbundance=no`，保留长度信息) → DESeq2；设计为 `~ condition`，对比为 `trt vs untrt`。过滤条件为至少 4 个样本中计数不低于 10；共检验 424 个基因。

显著阈值为 $FDR < 0.05$ 且 $|\log_2FC| \geq 1$ ，共 11 个基因。正的 $\log_2FC$ 表示 trt 中表达更高，负值表示 untrt 中表达更高。完整结果请以 TSV 为准，不应只使用显著列表。

主要输出位于同目录下的 `bulk\_rnaseq\_counts\_qc\_20260901/` 和 `bulk\_rnaseq\_de\_20260901/`。

OpenAI 的 NGS 分析 – 分析和结果目录



17 directories, 23 files

The image features a central graphic consisting of three concentric circles. The innermost circle is a light green ring, the middle one is a slightly darker green ring, and the outermost one is a very light green ring. Surrounding these circles are several solid-colored dots: a large olive green dot in the top-left, a small olive green dot in the top-right, a medium brown dot in the bottom-left, a large brown dot in the bottom-right, and a small brown dot in the upper-right quadrant. The text "Question time !!!" is centered horizontally across the middle of the image.

Question time !!!